

数据处理工具

使用说明

Excel · CSV · JSON · TXT · DOCX 多格式支持

读取 合并 拆分 透视 筛选 排序 匹配 清洗

数据可视化 (静态 + 交互式)

数据分析报告 (文本 / HTML / PDF)

批量处理 + 大文件分块读取

版本 1.0 | 2026年08月07日

运行: python main.py

目 录

一、快速开始

环境要求、启动方式

二、文件读取

支持格式、读取方式、预览

三、数据操作

筛选排序、合并拆分、透视聚合、查找匹配

四、数据清洗

缺失值、异常值、标准化

五、数据可视化

静态图表、交互式图表、仪表板

六、数据分析

描述统计、相关性、报告生成

七、PDF 导出

数据表导出、分析报告导出

八、批量处理

多文件批处理

九、常用技巧

编码处理、大文件、列操作

一、快速开始

1.1 环境要求

- Python 3.10 或以上
- 已安装依赖：pip install -r requirements.txt
- macOS / Windows / Linux 均可

1.2 启动

在终端中进入项目目录，运行：

```
cd 数据处理/  
python main.py
```

启动后显示主菜单，输入数字选择功能，按 0 返回上级或退出。

所有操作都基于"当前数据"。首先需要用菜单 1 读取文件，然后才能进行后续的数据操作、清洗、分析和可视化。

提示: 程序运行期间，当前数据保留在内存中，可以连续执行多种操作，无需重复读文件。

二、文件读取

2.1 支持的格式

格式	扩展名	说明
Excel (新版)	.xlsx	openpyxl 引擎
Excel (旧版)	.xls	xlrd 引擎，读取
CSV	.csv	逗号分隔，自动检测编码
TSV	.tsv	制表符分隔
JSON	.json	自动识别数组/嵌套结构
文本	.txt	按行或分隔符读取
Word	.docx	提取表格和段落文本

2.2 读取方式

- 菜单 1-1 **【读取单个文件】**：输入文件路径即可。Excel 文件会提示输入工作表名。
- 菜单 1-2 **【批量读取+合并】**：指定目录和扩展名，自动将所有匹配文件纵向合并为一个表，并添加 `_source_file` 列标记来源。
- 菜单 1-3 **【分块读取大文件】**：将大文件分成多块逐块读取再合并，避免内存溢出。可自定义每块行数。
- 菜单 1-4 **【扫描目录找文件】**：查看目录下有哪些数据文件及大小、修改时间。

2.3 数据预览与导出

- 菜单 1-6 预览前 N 行数据；菜单 1-7 查看每列的名称、类型、缺失数、唯一值数。
- 菜单 1-5 将当前数据导出为 Excel/CSV/JSON 等格式，文件保存在 `output/` 目录。

提示: CSV 文件编码自动检测支持 UTF-8、GBK、GB2312 等中文编码。

三、数据操作

3.1 筛选与排序

筛选支持 11

种运算符：==、!=、>、>=、<、<=、contains、startswith、endswith、between、isnull、notnull。

条件筛选示例：选择列"年龄"，运算符">"，值"25" → 筛选出年龄大于25的行。

列表筛选：输入逗号分隔的值列表，可选择"包含"或"排除"模式。

Top N：按某列数值取最大/最小的前 N 条。

排序：支持多列排序，可分别指定每列的升/降序方向。

去重：按指定列（或全部列）删除重复行。

3.2 合并与拆分

行合并（菜单 2-8）：将另一个文件的数据追加到当前数据下方，相当于 SQL UNION ALL。

键合并（菜单 2-7）：类似 SQL JOIN 或 Excel VLOOKUP。支持 left/right/inner/outer

四种方式，支持单键或多键关联。左右表键名不同时也可分别指定。

列操作（菜单 2-6）：选择/删除列、重命名、添加计算列（支持 df 表达式）、类型转换（int/float/str/datetime/category）、列重排序。

拆分（菜单 2-9）：三种方式——按某列的不同值拆分、按行数均匀拆分、按数值区间拆分。拆分结果自动保存到 output/ 目录。

3.3 透视与聚合

数据透视表（菜单 2-10）：指定行标签、列标签（可选）、值列和聚合函数，生成透视表。

分组聚合（菜单 2-11）：

按列分组，对多列分别应用不同聚合函数（sum/mean/count/min/max/median/std）。

交叉表（菜单 2-12）：统计两个分类变量的频数分布。

3.4 查找与匹配

VLOOKUP（菜单 2-13）：从另一文件按关联键查找并取回指定列，支持 left=保留所有 / inner=仅匹配。

模糊匹配（菜单 2-14）：按关键词在指定列中搜索包含该词的记录。

范围查找（菜单 2-15）：将数值列按区间分段，添加分类标签（如 0-60→不及格, 60-80→良好, 80-100→优秀）。

四、数据清洗

4.1 缺失值处理

查看报告（菜单 3-1）：显示每列的缺失数、缺失率、数据类型。

自动处理（菜单 3-2 auto 模式）：缺失率>50%的列自动删除；数值列用中位数填充；文本列用众数填充。

手动填充（菜单 3-3）：支持前向填充(ffill)、后向填充(bfill)、均值、中位数、众数、零值、插值7种方法。

注意: drop 模式会删除含缺失值的整行，慎用。建议先查看缺失报告再选择策略。

4.2 异常值处理

检测方法（菜单 3-4）：IQR法（默认， $Q1-1.5\times IQR$ 到 $Q3+1.5\times IQR$ ）、Z-Score法（ $|z|>3$ ）、百分位法（排除1%-99%外）。

移除异常值（菜单 3-5）：对指定数值列检测并移除异常值行。

4.3 其他清洗

删除重复行（菜单 3-6）：按指定列去重。

清理列名和空白（菜单 3-7）：自动清理列名中的换行/全角空格，去除文本列前后空白。

4.4 标准化与变换

Min-Max 归一化（菜单 3-8）：将数值缩放到 $[0, 1]$ 范围。

Z-Score 标准化（菜单 3-9）：转换为均值0、标准差1的分布。

对数变换（菜单 3-10）：对偏态分布数据取对数，使其更接近正态分布。

五、数据可视化

5.1 静态图表 (菜单 4-1 ~ 4-10)

生成 PNG 格式图片，保存在 output/charts/ 目录。

编号	图表类型	说明
4-1	柱状图	类别对比，支持水平/垂直、排序、TopN
4-2	折线图	趋势变化，支持多线对比
4-3	饼图/环形图	占比分布
4-4	散点图	两变量关系，可选颜色/大小维度+趋势线
4-5	直方图	数值分布 + KDE密度曲线
4-6	箱线图	分布特征 + 离群点，支持分组对比
4-7	热力图	矩阵数值颜色映射
4-8	相关性热力图	pearson/spearman/kendall
4-9	时间序列图	支持按M/W/Q重采样
4-10	组合仪表盘	多图组合在单张画布上

5.2 交互式图表 (菜单 4-11 ~ 4-20)

使用 Plotly 生成，输出为独立 HTML 文件，双击在浏览器中打开。支持缩放、平移、悬停查看数值、点击图例筛选等交互操作。

编号	图表类型	额外特性
4-11	交互式柱状图	悬停数值、缩放、导出图片
4-12	交互式折线图	多线对比、标记点切换
4-13	交互式饼图/环形图	动画、点击钻取
4-14	交互式箱线图	离群点悬停详情
4-15	交互式热力图	值标注、颜色标尺
4-16	相关性热力图	红蓝渐变色阶
4-17	交互式时间序列	时间轴缩放平移
4-18	交互式散点图	缩放、框选、多维度颜色
4-19	旭日图/矩形树图	层级数据交互钻取
4-20	交互式仪表板	多图组合+交互

提示: 交互式图表 HTML 文件约 4-5MB，可直接在浏览器中打开查看，也支持导出为 PNG。

六、数据分析

6.1 描述统计

- 菜单 5-1: 对全部数值列输出 count/mean/std/min/1%/5%/25%/50%/75%/95%/99%/max 等 12 个统计量。
- 菜单 5-2: 对指定列统计各取值的频数和累计占比。
- 菜单 5-3: 所有列的详细摘要——类型、缺失、唯一值、均值、中位数、范围。

6.2 相关性分析

- 菜单 5-4: 相关系数矩阵 (pearson=线性相关 / spearman=秩相关 / kendall=序相关)。
- 菜单 5-5: 自动提取最强相关对，按强度分类 (极强/强/中等/弱)。
- 菜单 5-6: 找与目标变量相关的所有列，可按阈值过滤。

6.3 报告生成

- 文本报告 (菜单 5-7): 在终端输出数据分析报告，可保存为 .txt 文件。包含数据概览、描述统计、缺失值、异常值、最强相关对。
- HTML 报告 (菜单 5-8): 生成格式化的网页报告，含样式和洞察建议。自动识别缺失率>30%的列、强相关对 ($|r| \geq 0.7$) 等关键发现。文件保存在 output/reports/。

提示: HTML 报告可在任何浏览器中打开查看，排版美观，适合分享。

七、PDF 导出

7.1 数据表导出 PDF

菜单 7-1: 将当前数据表导出为格式化的 PDF 文档。

- 自动检测中文字体 (macOS: 华文黑体; Windows: 微软雅黑)
- 自适应列宽 (根据内容长度计算最佳列宽)
- 自动分页 (每页重复表头, 交替行背景色)
- 支持选择横向(A3宽)或纵向纸张
- 宽表自动拆分为多组列, 分页展示

7.2 分析报告导出 PDF

菜单 7-2: 生成包含完整分析内容的 PDF 报告。报告结构:

- 封面页: 标题、数据规模、生成时间
- 数据概览: 行列数、缺失率、列清单
- 描述统计: 所有数值列的统计量
- 缺失值检测: 缺失数、缺失率排名
- 相关性分析: 系数矩阵 + 最强相关对 (含强度判断)
- 图表嵌入: 自动生成直方图和相关性热力图并嵌入

注意: 图表嵌入部分需要 matplotlib 支持。请确保系统已安装中文字体。

八、批量处理

8.1 批量处理流程

菜单 6 提供 5 种批量处理模式：

- 合并所有文件: 将匹配的所有文件合并为一个表，可选择保存。
- 逐文件处理: 对每个文件执行相同操作（如删除空行），分别输出。
- 合并后筛选排序: 合并 → 条件筛选 → 排序 → 保存。
- 合并后去重: 合并多个来源文件并去除重复行。
- 合并后分组聚合: 适合多日数据汇总（如按月汇总销售额）。

8.2 文件匹配

支持两种方式指定文件：

- 扩展名模式: 输入 ".xlsx" 会递归搜索当前目录下所有 .xlsx 文件。
- glob 模式: 输入 "data/2024*.csv" 匹配特定目录下的文件。

提示: 批量处理支持并行模式（`max_workers` 参数），可加速大量文件的处理速度。

九、常用技巧

9.1 编码问题

CSV/TXT 文件读取时自动检测编码（支持 UTF-8、GBK、GB2312、GB18030、Latin-1）。如果自动检测失败，可在配置文件中修改 FALLBACK_ENCODINGS。

输出 CSV 默认使用 UTF-8 BOM 编码，确保在 Excel 中直接打开中文不乱码。

9.2 大文件处理

对于超出内存的大文件：

- 使用分块读取（菜单 1-3），每块默认 10 万行（CSV）或 5 万行（Excel）。
- 在 config.py 中调整 CSV_CHUNKSIZE 和 EXCEL_CHUNKSIZE 参数。
- MAX_MEMORY_MB 默认 500MB，超出时会警告。
- 优先使用 CSV 格式（比 Excel 读取快 3-5 倍）。

9.3 列操作技巧

添加计算列时，表达式使用 df["列名"] 引用已有列：

```
df['销售额'] * df['利润率'] / 100
```

支持 numpy 函数: np.log(), np.sqrt() 等。

批量重命名时，格式为: 旧名1->新名1, 旧名2->新名2

9.4 组合操作

推荐的典型工作流：

- 1. 读取文件 → 2. 查看列信息 → 3. 清理列名
- 4. 处理缺失值 → 5. 类型转换 → 6. 异常值检测
- 7. 筛选/排序 → 8. 分组聚合 → 9. 可视化
- 10. 生成 HTML/PDF 报告 → 11. 导出结果

9.5 输出目录

目录	内容
output/charts/	静态图表(PNG) + 交互式图表(HTML)
output/reports/	HTML 报告 + PDF 报告
output/cleaned/	清洗后的数据文件
output/batch_result/	批量处理结果

注意: output/ 目录下的文件不会被 git 追踪，请放心使用。

附：功能快速索引

需求	菜单位置	说明
读取 Excel	1-1	键入路径，可选工作表
读取 CSV	1-1	自动检测编码
合并多个文件	1-2	指定目录+扩展名
大文件分块读	1-3	防止内存溢出
筛选数据	2-1~2-3	条件/列表/TopN
排序	2-4	支持多列排序
去重	2-5	按指定列去重
合并两个表	2-7~2-8	JOIN / UNION
数据透视表	2-10	类似Excel透视表
分组求和/平均	2-11	sum/mean/count...
VLOOKUP	2-13	从另一表查找值
模糊搜索	2-14	关键词匹配
缺失值处理	3-1~3-3	删除/填充/自动
异常值处理	3-4~3-5	IQR/Z-Score
归一化	3-8~3-10	MinMax/Z-Score/log
生成图表	4-1~4-20	静态+交互式
描述统计	5-1	12项统计指标
相关性分析	5-4~5-6	找出相关变量
HTML 报告	5-8	网页格式分析报告
导出 PDF	7-1~7-2	数据表/分析报告
批量处理	6	多文件一键处理